

# 主要内容

## 1.主成分分析法

### *Principal Component Analysis: PCA*

问题1. 如何确定主成分?

问题2. 如何基于主成分确定数据的降维表示?

问题3. 如何由 $r(r < p)$ 个主成分, 重构 $x$ ?

2. 应用之一--K-L变换在人脸识别中的应用举例

3. 应用之二--高维数据的低维显示

## 主成分分析实质：

借助正交线性变换，将一组观测数据由可能相关的特征描述转化由一系列互不相关的特征(主成分)描述。

## 主成分分析的目的：

- 特征提取
- 降维
- .....

## 问题描述：

设 (1) 原始特征空间特征向量  $\mathbf{x} = [x_1, \dots, x_p]^T$ ,

其中  $x_1, \dots, x_p$  统计相关

由于相关性, 使得各特征存在信息冗余

(2) 原始特征空间经**正交**线性变换 $\mathbf{A}$ , 得新特征空间

新特征  $\xi_i, i = 1, \dots, p$  无信息冗余

$$\boldsymbol{\xi} = [\xi_1, \dots, \xi_p]^T = \mathbf{A}^T \mathbf{x} = [\mathbf{a}_1, \dots, \mathbf{a}_p]^T \mathbf{x}$$

$$\text{其中 } \xi_i = \sum_{j=1}^p a_{ij} x_j = \mathbf{a}_i^T \mathbf{x}$$

**目标：**寻求**最优正交变换 $\mathbf{A}$** , 使新特征**方差最大**。

$$\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_p], \text{ 其中 } \mathbf{a}_i^T \mathbf{a}_j = \delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

## 各个变换特征(主成分)的确定原则

- (1)  $\xi_i$ 与 $\xi_j$ 互不相关( $i, j = 1, \dots, p$ 并且 $i \neq j$ )
- (2)  $\xi_1$ 是原始特征线性组合中的方差最大者.
- (3)  $\xi_2$ 是与 $\xi_1$ 不相关的原始特征线性组合中的方差最大者; 它对于原始数据中不能被 $\xi_1$ 解释的剩余部分, 拥有最大解释能力.
- (4)  $\xi_3$ 是与 $\xi_1, \xi_2$ 均不相关的原始特征线性组合中的方差最大者; 对于原始数据中不能被  $\xi_1, \xi_2$ 解释的剩余部分, 具有最大解释能力.....
- (5)  $\xi_1, \xi_2, \dots, \xi_p$ 分别称为关于原始特征向量 $\mathbf{x}$ 的第一, 第二,...,第 $p$ 个主成分。

## STEP1.确定 $a_1$ .

考虑新特征  $\xi_1 = \sum_{j=1}^p a_{1j} x_j = \mathbf{a}_1^T \mathbf{x} = \mathbf{x}^T \mathbf{a}_1$

各样本关于新特征 $\xi_1$ 的方差

$$\begin{aligned}\text{var}(\xi_1) &= E \left[ \left( \xi_1 - \hat{\xi}_1 \right)^2 \right] = E \left[ \left( \mathbf{a}_1^T \mathbf{x} - \mathbf{a}_1^T \hat{\mathbf{x}} \right) \left( \mathbf{x}^T \mathbf{a}_1 - \hat{\mathbf{x}}^T \mathbf{a}_1 \right) \right] \\ &= E \left[ \mathbf{a}_1^T \left( \mathbf{x} - \hat{\mathbf{x}} \right) \left( \mathbf{x} - \hat{\mathbf{x}} \right)^T \mathbf{a}_1 \right] \\ &= \mathbf{a}_1^T E \left[ \left( \mathbf{x} - \hat{\mathbf{x}} \right) \left( \mathbf{x} - \hat{\mathbf{x}} \right)^T \right] \mathbf{a}_1 \\ &= \mathbf{a}_1^T \Sigma \mathbf{a}_1\end{aligned}$$

$$\text{最优 } \mathbf{a}_1 \text{ 应满足 } \begin{cases} \max_{\mathbf{a}_1} \text{var}(\xi_1) = \mathbf{a}_1^T \Sigma \mathbf{a}_1 \\ \text{s.t. } \mathbf{a}_1^T \mathbf{a}_1 = 1 \end{cases}$$

构造 *Lagrang* 目标函数

$$\begin{cases} f(\mathbf{a}_1) = \mathbf{a}_1^T \Sigma \mathbf{a}_1 - v(\mathbf{a}_1^T \mathbf{a}_1 - 1) \\ v \text{ 为 } \textit{Lagrang} \text{ 乘子} \end{cases}$$

$$\frac{\partial f}{\partial \mathbf{a}_1} = 2(\Sigma \mathbf{a}_1 - v \mathbf{a}_1) = 0 \quad \rightarrow \quad \Sigma \mathbf{a}_1 = v \mathbf{a}_1$$

$\mathbf{a}_1$  为协方差矩阵  $\Sigma$  的 **本征值**  $v$  对应 **本征列向量**

$$\text{var}(\xi_1) = \mathbf{a}_1^T \Sigma \mathbf{a}_1 = v \mathbf{a}_1^T \mathbf{a}_1 = v$$

要使  $\text{var}(\xi_1)$  最大,  $v$  应为  $\Sigma$  最大本征值  $\lambda_1$

( $\xi_1$  为 **第一主成分**)

$\mathbf{a}_1$  为  $\Sigma$  对应本征值  $\lambda_1$  的本征列向量

## STEP2.确定 $a_2$ .

$a_2$ 应满足两个要求  $\begin{cases} \text{A. 新特征 } \xi_2 \text{ 与第一主成分 } \xi_1 \text{ 不相关} \\ \text{B. 除去 } \xi_1 \text{ 外, 新特征 } \xi_2 \text{ 方差最大} \end{cases}$

$$\text{其中 } \xi_2 = \sum_{j=1}^p a_{2j} x_j = \mathbf{a}_2^T \mathbf{x} = \mathbf{x}^T \mathbf{a}_2$$

**A.  $\xi_2$ 与 $\xi_1$ 不相关**

$$\text{协方差 } E \left[ \left( \xi_1 - \widehat{\xi}_1 \right) \left( \xi_2 - \widehat{\xi}_2 \right) \right] = 0$$

$$\begin{aligned} E \left[ \left( \xi_1 - \widehat{\xi}_1 \right) \left( \xi_2 - \widehat{\xi}_2 \right) \right] &= E \left[ \mathbf{a}_1^T \left( \mathbf{x} - \widehat{\mathbf{x}} \right) \left( \mathbf{x} - \widehat{\mathbf{x}} \right)^T \mathbf{a}_2 \right] \\ &= \mathbf{a}_1^T E \left[ \left( \mathbf{x} - \widehat{\mathbf{x}} \right) \left( \mathbf{x} - \widehat{\mathbf{x}} \right)^T \right] \mathbf{a}_2 = \mathbf{a}_1^T \Sigma \mathbf{a}_2 = \mathbf{a}_2^T \Sigma \mathbf{a}_1 = 0 \end{aligned}$$

由于  $\Sigma \mathbf{a}_1 = \lambda_1 \mathbf{a}_1$ , 所以  $\mathbf{a}_2^T \Sigma \mathbf{a}_1 = \lambda_1 \mathbf{a}_2^T \mathbf{a}_1 = 0$ 。

即:  $\xi_2$ 与 $\xi_1$ 不相关  $\Leftrightarrow \mathbf{a}_2, \mathbf{a}_1$ 正交。

## B. $\xi_2$ 的方差

$$\text{var}(\xi_2) = \mathbf{E} \left[ \left( \xi_2 - \hat{\xi}_2 \right)^2 \right]$$

$$= \mathbf{E} \left[ \mathbf{a}_2^T (\mathbf{x} - \hat{\mathbf{x}}) (\mathbf{x} - \hat{\mathbf{x}})^T \mathbf{a}_2 \right] = \mathbf{a}_2^T \Sigma \mathbf{a}_2$$

$$\text{最优 } \mathbf{a}_2 \text{ 应满足 } \begin{cases} \max_{\mathbf{a}_2} & \text{var}(\xi_2) = \mathbf{a}_2^T \Sigma \mathbf{a}_2 \\ \text{s.t.} & \mathbf{a}_2^T \mathbf{a}_2 = 1, \quad \mathbf{a}_1^T \mathbf{a}_2 = 0 \end{cases}$$

构造 *Lagrange* 目标函数

$$f(\mathbf{a}_2, \nu_2, \mu) = \mathbf{a}_2^T \Sigma \mathbf{a}_2 - \nu_2 (\mathbf{a}_2^T \mathbf{a}_2 - 1) - \mu \mathbf{a}_1^T \mathbf{a}_2$$



**Lagrange**目标函数

$$f(a_2, \nu_2, \mu) = a_2^T \Sigma a_2 - \nu_2 (a_2^T a_2 - 1) - \mu a_1^T a_2$$

$$\frac{\partial f}{\partial a_2} = 2\Sigma a_2 - 2\nu_2 a_2 - \mu a_1 = 0$$

两边左乘 $a_1^T$ ，有：

$$2a_1^T \Sigma a_2 - 2\nu_2 a_1^T a_2 - \mu a_1^T a_1 = 2a_1^T \Sigma a_2 - 0 - \mu = 0$$

$$\text{又 } a_1^T \Sigma a_2 = a_2^T \Sigma a_1 = \lambda_1 a_2^T a_1 = 0$$

$$\text{所以 } \mu = 0$$

$$\text{所以 } \Sigma a_2 - \nu_2 a_2 = 0$$

由前页

$$\Sigma \mathbf{a}_2 - \nu_2 \mathbf{a}_2 = 0$$

显然  $\nu_2$  为  $\Sigma$  的 **本征列向量**  $\mathbf{a}_2$  对应的 **本征值**

$$\text{所以 } \text{var}(\xi_2) = \mathbf{a}_2^T \Sigma \mathbf{a}_2 = \nu_2 \mathbf{a}_2^T \mathbf{a}_2 = \nu_2$$

要使  $\text{var}(\xi_2) = \nu_2$  最大

$\left\{ \begin{array}{l} \mathbf{a}_2 \text{ 必为 } \Sigma \text{ 剩余本征值中最大本征值 } \lambda_2 \text{ 对应的本征向量} \\ \nu_2 \text{ 应为 } \Sigma \text{ 第二大本征值 } \lambda_2 \\ \xi_2 \text{ 为 } \mathbf{\text{第二主成分}} \end{array} \right.$

### STEP3.确定其它 $a_i, i = 3, \dots, p$ , 及正交变换矩阵 $A$

样本协方差矩阵 $\Sigma$ 共有 $p$ 个本征值, 将其排列为

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

基于上述本征值对应本征向量 $a_i, i = 1, \dots, p$ , 可以构造**所有主成分** $\xi_i, i = 1, \dots, p$

各个主成分的方差满足  $\sum_{i=1}^p \text{var}(\xi_i) = \sum_{i=1}^p \lambda_i$

并且有  $\boldsymbol{\xi} = [\xi_1, \dots, \xi_p]^T = \mathbf{A}^T \mathbf{x} = [\mathbf{a}_1, \dots, \mathbf{a}_p]^T \mathbf{x}$

## 结论：

(1) 线性变换矩阵  $\mathbf{A} = [\mathbf{a}_1 \ \cdots \ \mathbf{a}_p]$  的各个列向量由协方差矩阵  $\Sigma$  的正交归一本征向量组成,  $\mathbf{A}^T = \mathbf{A}^{-1}$ .

-- $\mathbf{A}$  为正交矩阵,  $\boldsymbol{\xi} = \mathbf{A}^T \mathbf{x}$ ,  $\mathbf{x} = \mathbf{A} \boldsymbol{\xi}$

(2) 主成分方差满足  $\text{var}(\xi_i) = \lambda_i$   $\sum_{i=1}^p \text{var}(\xi_i) = \sum_{i=1}^p \lambda_i$

(3) 基于前  $k$  个主成分可描述数据信息比例  $d = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^p \lambda_i}$

通常求取的是“零均值化”的主成分  $\boldsymbol{\xi}$  
$$\begin{cases} \boldsymbol{\xi} = \mathbf{A}^T (\mathbf{x} - \boldsymbol{\mu}) \\ \mathbf{x} = \mathbf{A} \boldsymbol{\xi} + \boldsymbol{\mu} \end{cases}$$

## 基于主成分分析的特征降维

**A.** 基于 $p$ 维样本数据，估计**样本中心** $\mu$ 及**协方差矩阵** $\Sigma$

**B.** 确定 $\Sigma$ 的 $p$ 个**本征值**及**本征向量**,

得  $p$ 个本征值  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$

对应本征向量  $a_i, i = 1, \dots, p$

**C.** 确定**主成分数目** $r$   $r = \arg \min_k \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} \geq \alpha$

**D.** 确定 $p \times r$ 的变换矩阵 $A_r = [a_1 \ a_2 \ \dots \ a_r]$

**E.** 提取 $r$ 维零均值变换特征:  $\xi_r = A_r^T (x - \mu)$

# 主要内容

## 1. 主成分分析法

### *Principal Component Analysis: PCA*

问题1. 如何确定主成分?

问题2. 如何基于主成分确定数据的降维表示?

问题3. 如何由 $r$  ( $r < p$ ) 个主成分, 重构 $x$ ?

## 2. 应用之一--PCA在人脸识别中的应用举例

## 3. 应用之二--高维数据的低维显示

**人脸识别的一般概念：**给定一个场景中的静态图像或视频，利用给定的人脸数据库信息，**鉴别**或**确认**场景中的一位或多位人身份的过程。

一个完整的人脸识别系统通常包括三个部分：

(1) 图像获取

(2) 人脸检测与分割

(3) 人脸识别（特征选择与提取、模式匹配）

# 人脸识别方法的分类（根据特征提取方法）

## ➤ 第一类 基于表现（全局特征）的方法

全局匹配方法是用整个人脸区域作为输入，作为一个整体与已知人脸数据库进行匹配。

如 *Eigenfaces*, *Fisherfaces*, *SVM* 等。

## ➤ 第二类：基于结构（局部特征）的方法

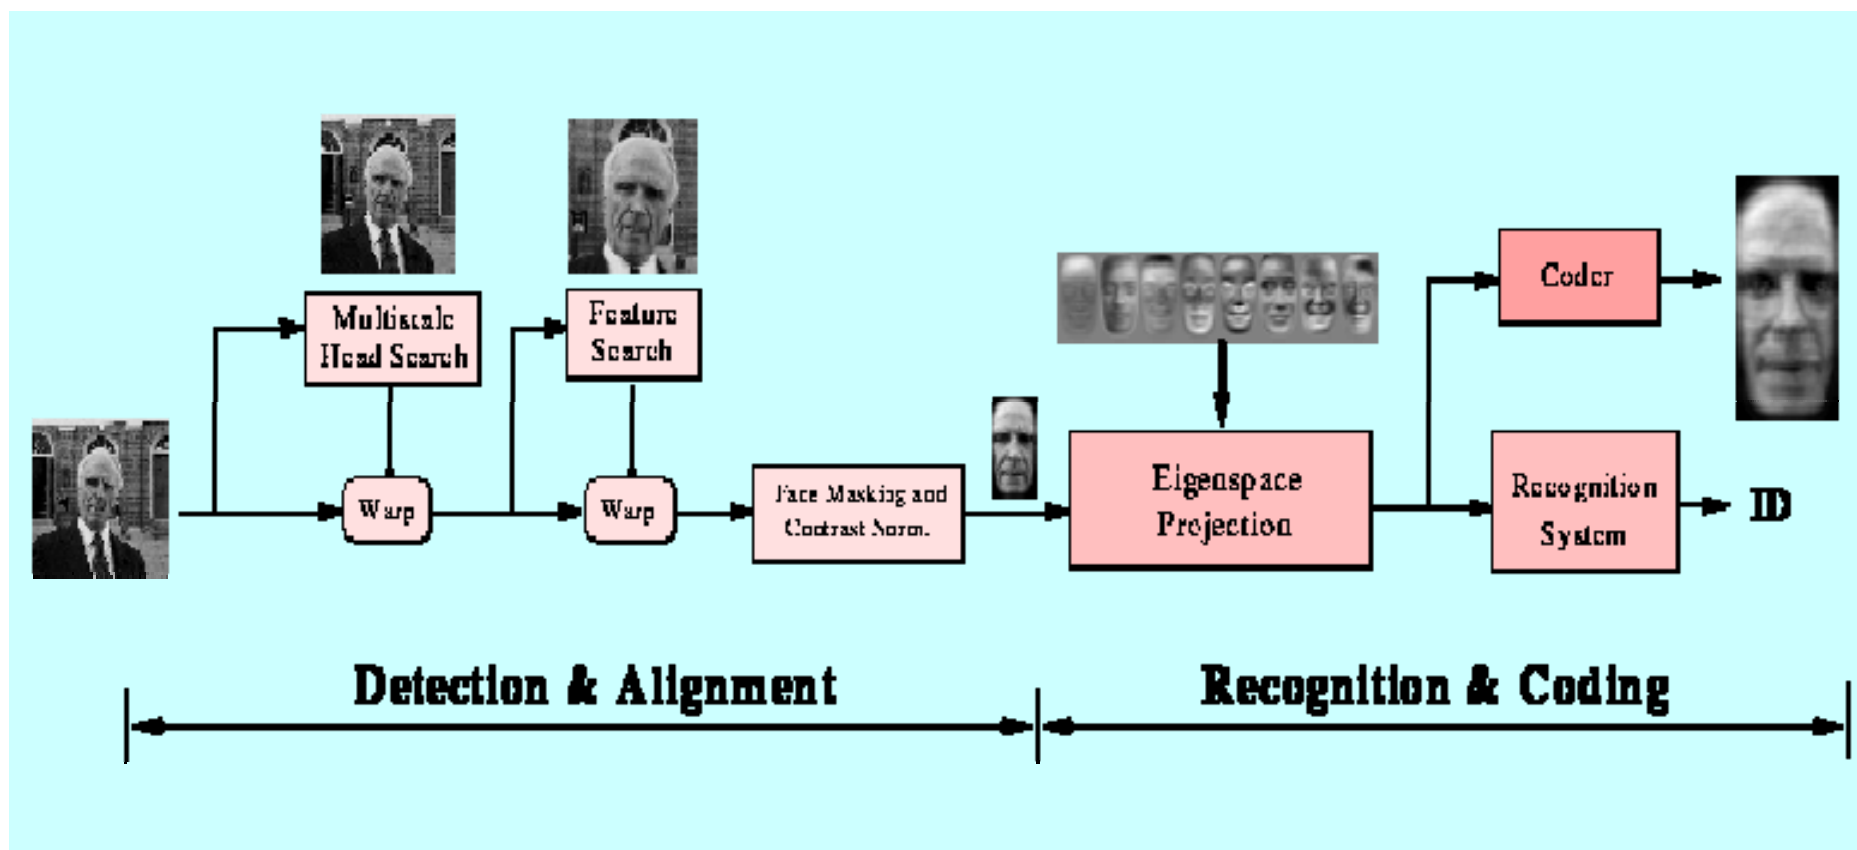
基于局部特征的结构匹配方法是根据人脸图中的局部特征（眼睛、鼻子、嘴巴等）在人脸图像中的位置和各自自身的结构确定对人脸图像进行识别。

如 *HMM Based Method* 等。



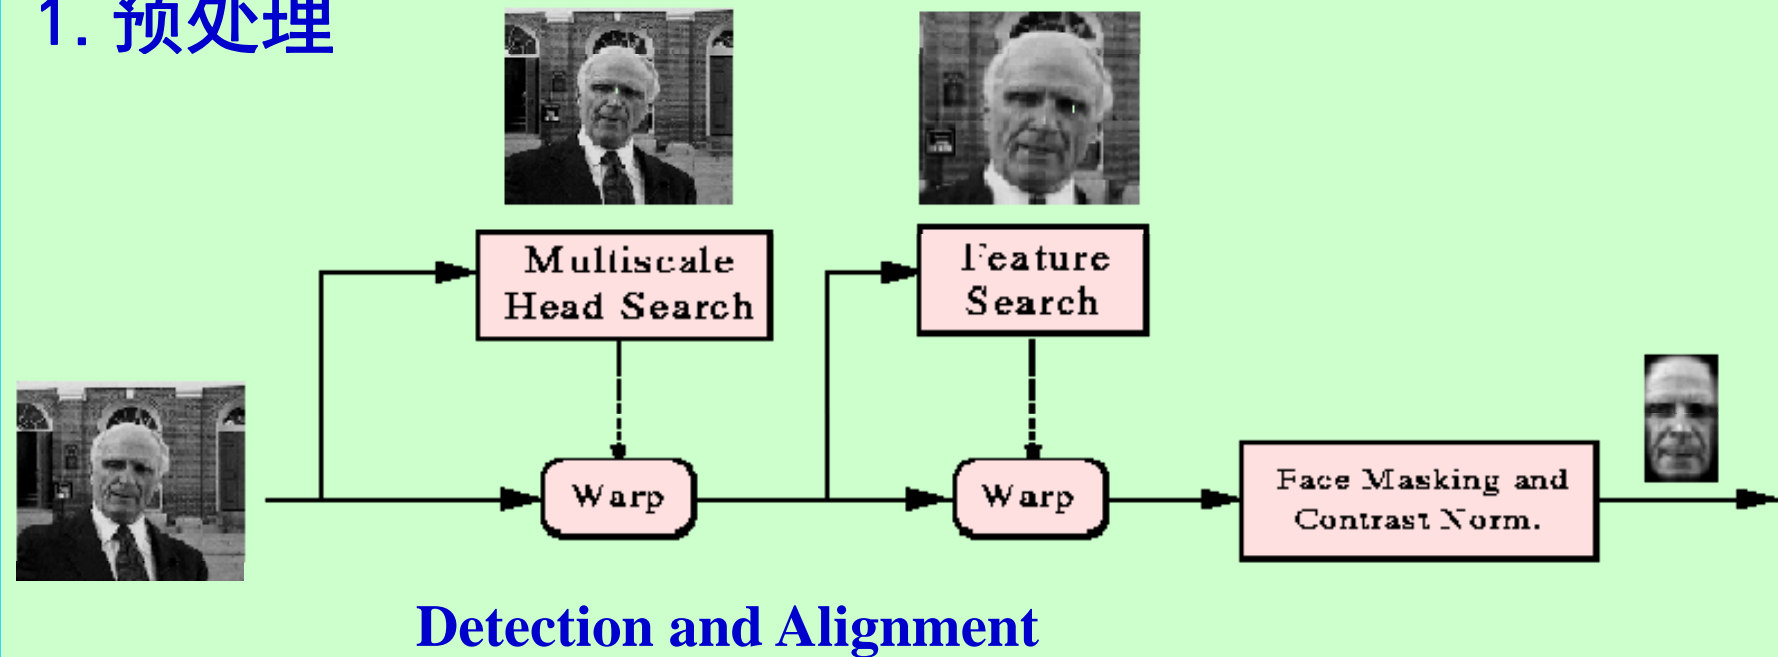


## 例：MIT人脸识别系统流程图

<http://vismod.media.mit.edu/vismod/demos/facerec/>



## 1. 预处理



*(1)Original Input Image; (2)Estimated Head Location & Scale; (3)Head-Centered Image; (4)Estimated Facial Feature Locations; (5) Warped & Masked Facial Region*

## 预处理阶段：

### ➤ 人脸图像的分割与脸部主要器官定位；

人脸正面图像；

左右两眼中心位置

### ➤ 图像归一化与裁剪


#### 图像几何校准：

图像旋转，使两眼中心连线水平；

图像裁剪： $2d \times 2d$

图像放缩，使其大小统一，如： $2d \times 2d \rightarrow 128 \times 128$

灰度拉伸：直方图修正，消除光照影响

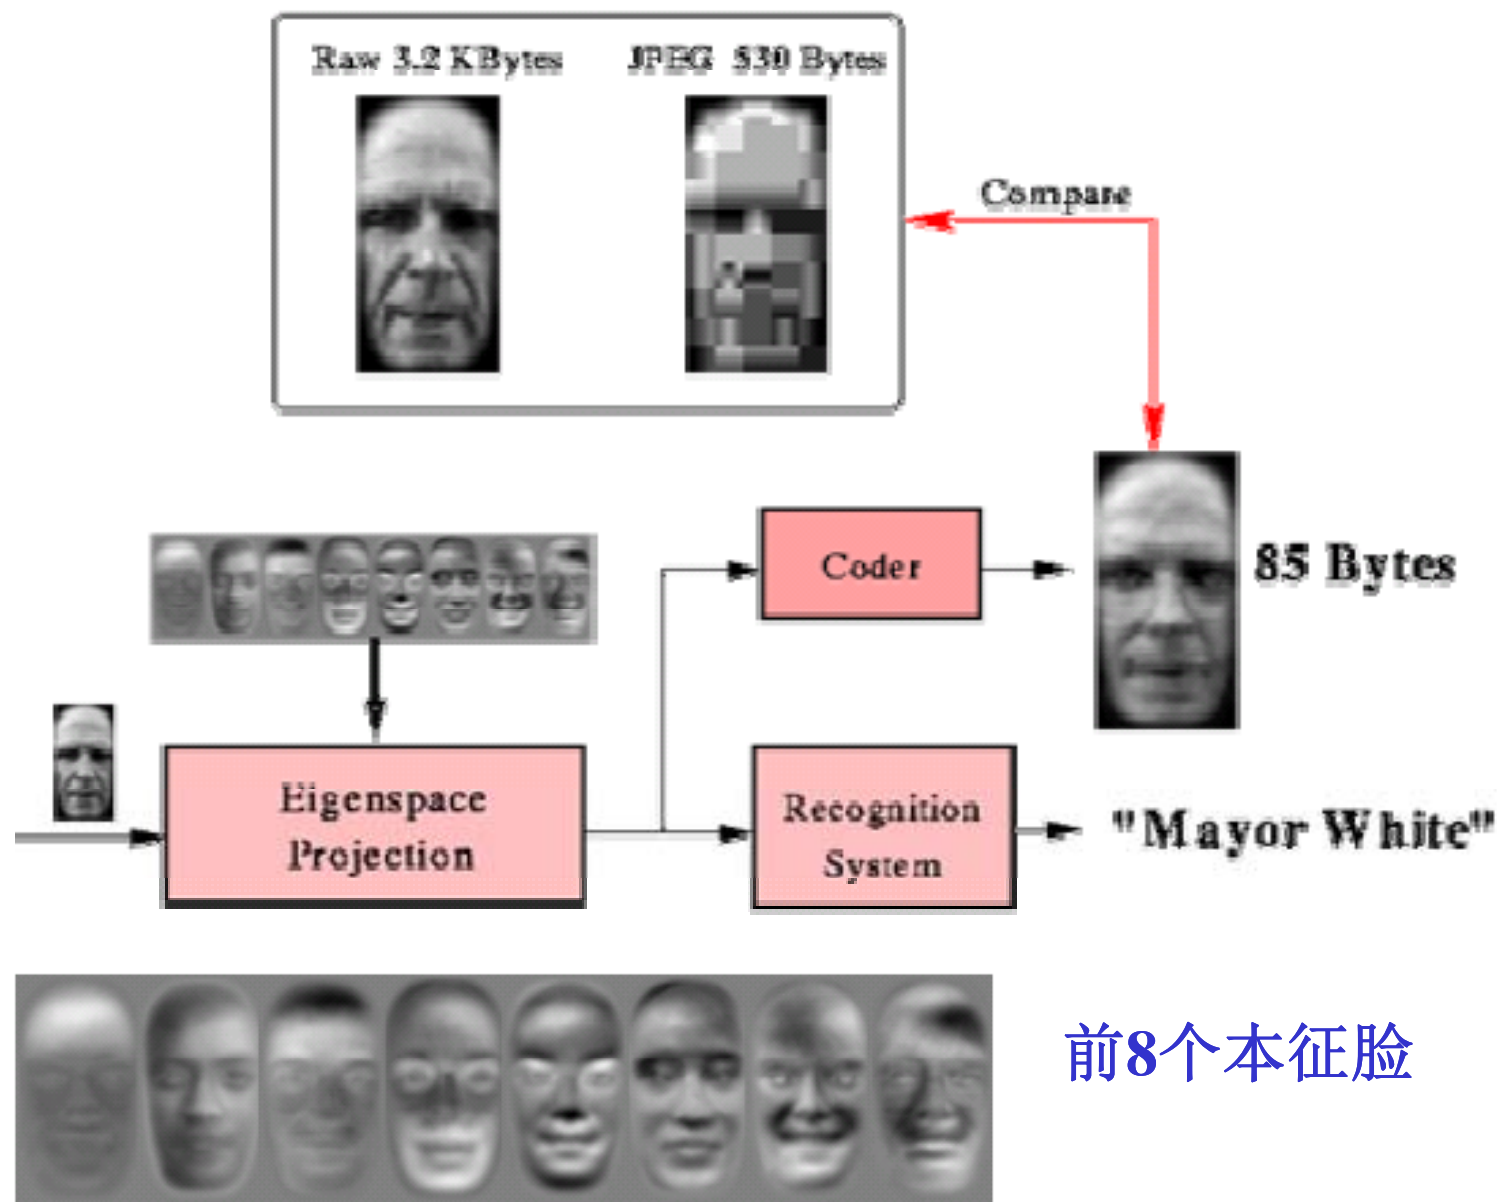


预处理阶段:

归一化部分  
人脸图像



## 2. 特征提取：本征脸的提取和表示



## PCA: 本征脸的提取和表示

### ➤ 训练样本集:


假定进行身份注册的人脸库中含有 $p$ 个人，共计 $m$ 幅图像。

每一幅图像都是归一化的标准图像。

所有图像构成训练样本集:

$$x_i \in R^{N^2} \quad i = 1, \dots, m$$

$m$  —— 标准图像的数量



### ➤ PCA

训练样本集  $\mathbf{x}_i \in \mathbf{R}^{N^2} \quad i = 1, \dots, m$

$m$  —— 训练样本（标准图像）数量

## [1] 确定PCA所需样本总协方差矩阵

$$\Sigma = E \left[ (\mathbf{x} - \mu)(\mathbf{x} - \mu)^T \right] \approx \frac{1}{m} \sum_{i=1}^m (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^T = \frac{1}{m} \mathbf{X} \mathbf{X}^T$$

$$\left\{ \begin{array}{l} \mu \text{ —— 训练样本集的平均向量（平均脸）} \quad \mu = \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i \\ m \text{ —— 标准图像数量} \\ \mathbf{X} = [\mathbf{x}_1 - \mu, \mathbf{x}_2 - \mu, \dots, \mathbf{x}_m - \mu] \quad N^2 \times m \text{ 维矩阵} \end{array} \right.$$

$\Sigma$  是一个  $N^2 \times N^2$  矩阵， $N^2 \gg m$ ， $\text{rank}(\Sigma) \leq \min\{N^2, m\}$

直接计算  $\Sigma$  的本征向量，非常困难。

→ 采用 **SVD** (*Singular Value Decomposition*) 方法

## [2] 基于SVD的矩阵 $\Sigma$ 本征值和本征向量求解

构造矩阵  $R = X^T X$ , 为  $m \times m$  矩阵 ( $m \ll N^2$ )

矩阵  $R$  的特征方程  $R v_i = \lambda_i v_i$  即  $X^T X v_i = \lambda_i v_i$

$$X X^T X v_i = \lambda_i X v_i \quad \text{即} \quad \Sigma X v_i = \lambda_i X v_i$$

$$\text{记 } u_i = X v_i \quad \text{则} \quad \Sigma u_i = \lambda_i u_i$$

矩阵  $\Sigma = X X^T$  与矩阵  $R = X^T X$  具有相同**本征值**  
对应**本征向量**关系  $u_i = X v_i$

$R$  为  $m \times m$  矩阵 ( $m \ll N^2$ ), 容易求取:

**本征值**  $\lambda_i$ , 及正交归一**本征向量**  $v_i$  ( $i = 1, \dots, m$ )



若 矩阵  $\mathbf{R} = \mathbf{X}^T \mathbf{X}$  的本征向量  $\mathbf{v}_i$  ( $m$  维向量)

则 矩阵  $\Sigma = \frac{1}{m} \mathbf{X} \mathbf{X}^T$  的归一化本征向量  $\mathbf{u}_i = \frac{1}{\sqrt{\lambda_i}} \mathbf{X} \mathbf{v}_i$

-- $N^2$  维向量 (即  $N \times N$  图像), 本征脸 “*eigenfaces*”

将  $\Sigma$  本征值由大到小排列  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq \dots \geq \lambda_m$   
对应本征向量  $\mathbf{u}_i$ ,  $i = 1, \dots, m$

每一幅人脸图像可投影到  $\mathbf{u}_1, \dots, \mathbf{u}_m$  所张成的子空间中;

每一幅人脸图像对应该子空间一点;

任一幅人脸图像均可表示成 “本征脸” 的线性组合,

其加权系数为 K-L 变换的展开系数。

### [3] 投影子空间的生成

尽管  $m \ll N^2$ , 但  $m$  仍很大, 可根据需要, 对  $m$  个本征向量有所舍取。

设信息压缩比  $\alpha$  ( $\alpha = 95\%$ ), 取前  $k$  个本征向量,

满足: 
$$k = \arg \min_{1 \leq d \leq m} \left( \frac{\sum_{i=1}^d \lambda_i}{\sum_{i=1}^m \lambda_i} \geq \alpha \right)$$

构造变换矩阵  $U = [u_1 \quad \cdots \quad u_k]$

## [4] 特征提取：投影到空间的样本描述

$$y = U^T (x - \mu)$$

思考：特征提取后，如何做进一步的身份识别或鉴别？

## 基于压缩信息的人脸近似重构

$$\hat{x} = \sum_{j=1}^k y_j u_j + \mu = Uy + \mu$$

# 主要内容

## 1. 主成分分析法

### *Principal Component Analysis: PCA*

问题1. 如何确定主成分?

问题2. 如何基于主成分确定数据的降维表示?

问题3. 如何由 $r$  ( $r < p$ ) 个主成分, 重构 $x$ ?

## 2. 应用之一--PCA在人脸识别中的应用举例


## 3. 应用之二—彩色图像的压缩

# Example – PCA to compress color images

- Recall that a color image is made up of pixels with red, green, blue (RGB) values.
- Essentially, we have a collection of 3D vectors in RGB space.



Image “peppers.png”



Pixels in RGB space (only 1% are shown)

```

clear all
close all

RGB = im2double(imread('peppers.png'));

% Convert 3-dimensional array array to 2D, where each row is a pixel (RGB)
X = reshape(RGB, [], 3);
N = size(X,1); % N is the number of pixels

% Plot pixels in color space. To limit the number of points, only plot
% every 100th point.
figure
hold on
for i=1:100:size(X,1)
    mycolor = X(i,:);
    mycolor = max(mycolor, [0 0 0]);
    mycolor = min(mycolor, [1 1 1]);
    plot3(X(i, 1), X(i, 2), X(i, 3), ...
          '.,', 'Color', mycolor);
end
xlabel('red'), ylabel('green'), zlabel('blue');
xlim([0 1]), ylim([0 1]), zlim([0 1]);
hold off
axis equal
% Rotate the display.
for az=-180:3:180
    view(az,30); % set azimuth, elevation in degrees
    drawnow;
end

```

Code to convert RGB  
color image to a set of  
vectors, and plot them

# Example (continued)

- Can we use fewer than 3 values per pixel?
- Do PCA on color vectors ... keep the top two PCs.

```
% Get mean and covariance
mx = mean(X);
Cx = cov(X);

%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
% Get eigenvalues and eigenvectors of Cx.
% Produces V,D such that Cx*V = V*D.
% So the eigenvectors are the columns of V.
[V,D] = eig(Cx);
e1 = V(:,3);
disp('Eigenvector e1:'), disp(e1);
e2 = V(:,2);
disp('Eigenvector e2:'), disp(e2);
e3 = V(:,1);
disp('Eigenvector e3:'), disp(e3);

d1 = D(3,3);
disp('Eigenvalue d1:'), disp(d1);
d2 = D(2,2);
disp('Eigenvalue d2:'), disp(d2);
d3 = D(1,1);
disp('Eigenvalue d3:'), disp(d3);
```

Eigenvector e1:

-0.8239  
-0.5611  
-0.0793

Eigenvector e2:

-0.3262  
0.3551  
0.8761

Eigenvector e3:

-0.4634  
0.7477  
-0.4756

Eigenvalue d1:

0.0912

Eigenvalue d2:

0.0296

Eigenvalue d3:

0.0140

# Example (continued)

- Construct the “A” matrix, whose rows are the eigenvectors of Cx

```
% Construct matrix A such that the 1st row of A is the eigenvector  
% corresponding to the largest eigenvalue, the 2nd row is the eigenvector  
% corresponding to the second largest eigenvalue, etc.  
A = [e1'; e2'; e3'];
```

- Project input vectors onto the PCs



```
% Project input vectors x onto eigenvectors. For each (column) vector x,  
% we will use the equation  $y = A*(x - mx)$ .  
% To explain the Matlab commands below:  
% X is our (N,3) array of vectors; each row is a vector.  
% mx is the mean of the vectors, size (1,3).  
% We first subtract off the mean using  $X - \text{repmat}(mx, N, 1)$ .  
% We then transpose that result so that each vector is a column.  
% We then apply our transform A to each column.  
Y = A*(X - repmat(mx, N, 1))'; % Y has size 3xN
```



# Example (continued)

- Display the y vectors as images

```
% Display y vectors as images
[height,width,depth] = size(RGB);
Y1 = reshape(Y(1,:), height, width);
Y2 = reshape(Y(2,:), height, width);
Y3 = reshape(Y(3,:), height, width);
figure;
subplot(1,3,1), imshow(Y1,[]);
subplot(1,3,2), imshow(Y2,[]);
subplot(1,3,3), imshow(Y3,[]);
```




# Example (continued)

- Form the  $A_k$  matrix by taking only the top  $k$  rows of  $A$
- Reconstruct the  $\mathbf{x}$  vectors using only the top  $k$  PC's:

$$\mathbf{x}' = \mathbf{A}_k^T \mathbf{y} + \mathbf{m}_x$$

- Plot the  $\mathbf{x}$  vectors in RGB space.



# Example (continued)

- Put the x vectors back into the form of an RGB image, using “reshape”.

Original



Reconstructed

